

Análisis de la evolución de la eficiencia energética de las plantas nucleares en Estados Unidos.

Abstracto:

En este proyecto se analiza la evolución histórica de la eficiencia energética de las plantas nucleares en Estados Unidos, país que destaca por contar con una gran cantidad de reactores nucleares activos y por ofrecer acceso a numerosos datos públicos. A través de diferentes modelos de regresión, se estudian posibles escenarios futuros con el objetivo de evaluar si la construcción de nuevas plantas nucleares podría ser una alternativa viable y eficiente. El proyecto se enmarca en el contexto del actual desafío global relacionado con la producción energética sostenible, buscando identificar soluciones que maximicen la eficiencia energética y minimicen los impactos negativos sobre el medio ambiente.

Introducción:

¿Qué es la energía Nuclear?

La energía nuclear es la energía liberada durante las reacciones nucleares, ya sea por fisión (división del núcleo atómico) o fusión (unión de núcleos ligeros). En la fisión nuclear, se divide un núcleo atómico pesado en dos o más núcleos más ligeros, liberando grandes cantidades de energía. En la fusión nuclear, los núcleos ligeros se unen para formar un núcleo más pesado, también liberando energía.

A lo largo de la historia de los reactores nucleares, se han utilizado 3 combustibles principales, que son: Uranio-238, Uranio-235 y Plutonio-239. De los 3, los mas usados son Uranio-238 y Uranio-235, esto se debe a que el Uranio es un material mucho mas abundante en la naturaleza, se puede extraer mediante minería a gran escala, es mas fácil de tratar y de enriquecer, por tanto, más fácil crear los isótopos deseados para las plantas nucleares, y además, el Plutonio es altamente radiotóxico, y por tanto mas peligroso a la hora de manejarlo.

¿Qué es una Planta Nuclear?

Una planta nuclear es una instalación industrial diseñada para generar electricidad a través de la energía liberada en reacciones nucleares controladas. Estas instalaciones comprenden varios reactores nucleares, sistemas de seguridad, controles de operación, y sistemas de manejo y almacenamiento de combustible nuclear y residuos radiactivos, su corazón es el reactor nuclear.

Reactor nuclear: Es donde se llevan a cabo las reacciones nucleares controladas para generar calor. Estos reactores utilizan combustible nuclear, para producir energía

térmica mediante la fisión nuclear. El calor generado se convierte en energía eléctrica a través de un ciclo termodinámico convencional, como un ciclo de vapor.

De momento, los reactores nucleares se centran en la fisión nuclear por que la fusión nuclear, aunque libera mucha más energía, también requiere más energía para producirla y de momento no se han producido generaciones de energía neta mediante este método, aun que es un campo en desarrollo.

Hoy en día, la energía nuclear es una fuente importante de energía, aunque es cierto que requiere una gran inversión inicial, es capacidad de producir una gran cantidad de energía por planta nuclear, para perspectiva, con alrededor de 60 plantas nucleares, se consigue un 18,5% de la energía total generada, mientras que por ejemplo, para el gas natural, se necesitan mas de 1600 plantas para generar alrededor del 40%, es decir más de 800 plantas de gas natural para generar la misma cantidad de energía que 60 plantas nucleares.

Las variables de nuestros datos son las siguientes:

Total operable Units (Total de unidades operativas):

Es la cantidad de reactores activos. Estos no es lo mismo que cantidad de plantas nucleares activas, dado que una planta puede contener mas de un reactor, lo cual es relativamente común.

Nuclear Electricity Net Generation (Generación neta de electricidad por energía nuclear):

Es la energía neta, es decir, la diferencia entre la generada y la consumida, que producen las plantas nucleares, se mide en GW/h.

Nuclear Share of Electricity Net Generation (Participación de la energía nuclear en el total de energía neta generada):

Es el porcentaje de la energía total generada en estados unidos, que se debe a la energía nuclear.

Capacity Factor (Factor de Capacidad):

Es el porcentaje de tiempo que las plantas nucleares operan a su capacidad máxima teórica. Lo ideal sería que se fuera siempre 100%, aun que valores por encima del 85% son ya bastante buenos, y ocasionalmente pueden estar por encima del 100% por desfase de las actualizaciones de las plantas y las capacidades de estas.

Capacidad neta en verano de las unidades nucleares (Nuclear Generating Units, Net Summer Capacity):

Es la capacidad máxima de generación de electricidad que pueden producir las plantas nucleares en condiciones de calor del verano. Se mide en megavatios eléctricos (MWe) y representa la potencia máxima sostenida que una central puede suministrar en la red en esas condiciones.

A la hora de realizar nuestros análisis, adoptaremos dos decisiones metodológicas clave. En primer lugar, se dividirán todas energía neta generada entre el número total

de unidades operativas, en lugar de hacerlo por planta nuclear. Esta elección se justifica en que algunas plantas albergan múltiples reactores, lo cual podría distorsionar los resultados si se tomara la planta como unidad de referencia. Al normalizar los datos por unidad operativa, se obtiene una visión más precisa y representativa de la eficiencia real de la energía nuclear.

En segundo lugar, se optará por omitir, en términos generales, la variable Share of Electricity (%). Aunque esta métrica ofrece una aproximación al peso relativo de la energía nuclear dentro del mix energético de un país, su valor depende en gran medida de factores exógenos al rendimiento de los reactores. Por ejemplo, un descenso en este porcentaje podría deberse no a una disminución en la producción nuclear, sino a un incremento desproporcionado en otras fuentes de energía. Por tanto, se considera que esta variable no refleja de forma fiable la eficiencia o productividad inherente de las instalaciones nucleares.

En el análisis exploratorio de datos (EDA), se adoptó un enfoque sistemático orientado a mejorar la comprensión del conjunto de datos y garantizar su adecuación para análisis predictivos posteriores. El proceso comenzó con la depuración de valores irrelevantes, con el objetivo de preservar la calidad y coherencia de la información. A continuación, se identificó la variable principal, seleccionando aquella con mayor relevancia en relación con el fenómeno de estudio (Net Generation).

La exploración gráfica permitió visualizar la evolución temporal de los datos y las relaciones entre variables clave, facilitando la interpretación de tendencias y patrones. Asimismo, se aplicaron medias móviles para suavizar variaciones puntuales y detectar tendencias a largo plazo, complementadas con el análisis de estacionalidad para identificar comportamientos recurrentes a lo largo del tiempo.

Por último, se evaluaron diferentes enfoques de predicción, incluyendo modelos de series temporales, regresión y métodos de aprendizaje automático, en función de la estructura de los datos y los objetivos analíticos. Este enfoque integral asegura una preparación sólida para etapas posteriores de modelado y toma de decisiones basada en datos.


Metodología:

EDA:

El objetivo principal de este análisis es proyectar la evolución de los datos en el medio y largo plazo, por lo que se ha priorizado la selección de las variables más representativas para dicho propósito. Como primer paso, se transformaron los datos originales en valores relativos por cada reactor activo, con el fin de obtener una representación más precisa de la evolución de la eficiencia operativa del sistema nuclear.

El conjunto de datos abarca desde enero de 1973 hasta noviembre de 2024. Sin embargo, entre enero de 1973 y diciembre de 1994, se identificó una carencia sustancial de información: en 242 de los primeros 263 meses no se registran datos sobre el número de reactores activos. Dada esta falta de continuidad, se optó por excluir ese tramo inicial y centrar el análisis a partir de 1995. Esta decisión no solo mejora la consistencia temporal del conjunto de datos, sino que también proporciona una base más realista para las predicciones, al reflejar un periodo en el que la tecnología nuclear ya había alcanzado un mayor grado de madurez. De esta forma, se evita que el modelo se vea afectado por la volatilidad y el crecimiento acelerado propios de la fase inicial de desarrollo tecnológico.

Para el tratamiento y limpieza de los datos se utilizaron principalmente las librerías NumPy y Pandas, dada su eficiencia en la manipulación de estructuras como DataFrames y Series, que resultan fundamentales para el posterior análisis y modelado. Asimismo, se empleó la librería Matplotlib para la representación gráfica básica de las variables, facilitando la visualización de tendencias y validación visual del proceso de transformación de datos.




A partir de una inspección inicial de los datos, se pueden identificar varias observaciones relevantes. En primer lugar, se evidencia una disminución progresiva en el número de reactores activos, así como una ligera caída en la capacidad neta

durante los meses de verano. No obstante, a pesar de esta reducción en la infraestructura operativa, tanto la energía neta generada como la capacidad promedio por reactor han mostrado una tendencia ascendente a lo largo del periodo analizado.


Una vez seleccionados los datos mensuales comprendidos entre diciembre de 1994 y noviembre de 2024, se procedió a su representación gráfica. Este paso tuvo como objetivo realizar un análisis exploratorio preliminar que permitiera observar visualmente el comportamiento de las principales variables normalizadas por reactor activo. Dicha visualización facilita la detección de patrones, anomalías o tendencias que pueden ser relevantes para el desarrollo de modelos predictivos más precisos en fases posteriores del estudio.

Variables por Unidad Operativa



Al analizar las variables normalizadas por unidad operativa, se observa con claridad que, a pesar de la disminución significativa en el número de reactores activos, la mayoría de las variables consideradas —con excepción del Share of Electricity (%) y la Net Summer Capacity— presentan una tendencia general al alza. En particular, la Net Summer Capacity, aunque ha experimentado un leve descenso a lo largo del tiempo, continúa situándose dentro de un rango relativamente estable, sin variaciones bruscas que indiquen una pérdida sustancial de rendimiento.

Con el apoyo de la librería Seaborn, se generó un mapa de correlación entre las variables, lo cual permite identificar de forma visual la intensidad y dirección de las relaciones existentes entre ellas. Esta representación constituye una herramienta clave para detectar redundancias, dependencias lineales y posibles indicadores con valor predictivo relevante para el análisis posterior.



Tal como se ha expuesto anteriormente, las variables Net Generation, Net Summer Capacity y Capacity Factor (%) presentan una alta correlación entre sí, lo que sugiere una relación estructural coherente entre la capacidad instalada, el rendimiento operativo y la generación efectiva de energía. En contraste, la variable Share of Electricity (%) muestra una correlación mucho más débil con el resto, lo cual respalda la hipótesis de que esta métrica depende en mayor medida de factores externos al sistema nuclear, como el crecimiento de otras fuentes de energía en el mix energético nacional o cambios en la demanda eléctrica global.

En síntesis, tras el proceso de limpieza, transformación y análisis exploratorio de los datos, se ha decidido trabajar exclusivamente con el subconjunto de datos a partir de diciembre de 1994. Además, se transformarán las variables seleccionadas en valores por unidad operativa activa, con el fin de obtener mediciones más representativas de la eficiencia de cada reactor. Finalmente, para los análisis predictivos, se empleará la variable Net Generation como variable objetivo principal, mientras que Net Summer Capacity y Capacity Factor (%) serán utilizadas como variables exógenas de apoyo.

Entrenamiento de modelo y predicción:

Para el proceso de entrenamiento, evaluación y predicción, además de las librerías previamente mencionadas (Pandas, NumPy, Matplotlib y Seaborn), se ha hecho uso de las librerías especializadas Scikit-learn (sklearn) y Skforecast, que permiten importar y aplicar modelos de regresión adecuados para tareas de predicción, así como evaluar su rendimiento de forma sistemática.

Es fundamental destacar que el conjunto de datos empleado corresponde a una serie temporal, es decir, un conjunto de observaciones organizadas cronológicamente. Por lo tanto, cualquier modelo destinado a realizar forecasting debe tener en cuenta esta estructura temporal, ya que los valores futuros dependen, en gran medida, de patrones, tendencias y variaciones históricas.

A lo largo del proyecto se han considerado diversas estrategias de ajuste para modelar tanto la variable principal, Net Generation, como las variables exógenas Net Summer Capacity y Capacity Factor (%). Las opciones exploradas para el ajuste de estas series incluyen:

SARIMAX:

Es un modelo estadístico clásico, no basado en Machine Learning ni Deep Learning.

Tiene en cuenta la tendencia, estacionalidad, y los residuos autorregresivos de una serie temporal.

Además, permite incorporar variables externas (exógenas) para mejorar las predicciones.

Es ideal cuando los patrones de la serie son estables en el tiempo y no se requiere modelar relaciones complejas entre múltiples variables.

Ventajas: Interpretabilidad, bajo coste computacional, buen rendimiento en series limpias.

Limitaciones: No capta relaciones no lineales ni interacciones complejas entre múltiples variables.

Regresión lineal (Ridge):

Es una forma regularizada de la regresión lineal que añade una penalización L2 para evitar el sobreajuste.

En contextos multivariantes, puede captar la influencia conjunta de varias variables exógenas.

Aunque no modela la estacionalidad directamente como SARIMAX, puede aproximarla si se incorporan variables como “mes”, “año”, “tendencia”, etc.

Tiene un coste computacional bajo y se comporta muy bien si la relación entre variables es lineal.

Ventajas: Simplicidad, eficiencia, buena base teórica.

Limitaciones: No capta relaciones no lineales complejas, sensible a multicolinealidad si no se regulariza bien.

GradientBoosting:

Es un modelo de ensamble basado en árboles de decisión, donde cada nuevo árbol corrige los errores del anterior.

Funciona bien con relaciones no lineales, interacciones entre variables y datos con ruido moderado.

Tiene un coste computacional más alto, especialmente si se incrementa el número de árboles o la profundidad.

Muy eficaz en problemas donde no hay una estructura temporal fuerte pero sí mucha complejidad en las variables.

Ventajas: Alta precisión, manejo de datos no lineales, buena capacidad de generalización.

Limitaciones: Entrenamiento más lento, menos interpretable, puede sobreajustar si no se regula bien.

MLP (Multilayer Perceptron):

Es una red neuronal feedforward con al menos una capa oculta.

Utiliza funciones de activación como ReLU o tanh, y se entrena con backpropagation y descenso del gradiente.

Es capaz de modelar relaciones muy complejas y no lineales entre múltiples variables.

Requiere más datos y procesamiento, y es menos interpretable, pero su potencia en tareas complejas es alta.

Ventajas: Flexibilidad para capturar relaciones complejas, adaptable a muchos problemas.

Limitaciones: Requiere ajuste fino de hiperparámetros, mayor tiempo de entrenamiento, menor interpretabilidad.

SVR(Support Vector Regression):

Es la versión para regresión de las máquinas de soporte vectorial (SVM).

Utiliza kernels (lineal, polinómico, radial - RBF) para proyectar los datos a espacios de mayor dimensión y encontrar una función que se mantenga dentro de un margen de tolerancia (ϵ).

Es muy robusto a outliers y puede funcionar muy bien con pocos datos, especialmente en problemas con relaciones complejas.

Ventajas: Precisión, capacidad de modelar relaciones no lineales, robustez.

Limitaciones: Más lento para conjuntos grandes, requiere elegir bien el kernel y sus parámetros.

Con el fin de determinar cuál de los modelos considerados ofrece un mejor ajuste a los datos, se procedió a entrenar cada uno de forma independiente y a evaluar su rendimiento mediante el cálculo del error relativo. Este proceso se llevó a cabo tanto bajo el enfoque recursivo como bajo el enfoque directo. Ambos métodos permiten realizar predicciones basadas en la secuencia temporal de los datos, proporcionando así estimaciones más representativas del comportamiento futuro de la serie.

Para implementar estos modelos de predicción, se desarrollaron dos etapas clave. En primer lugar, fue necesario introducir lags (o rezagos), que representan el número de

observaciones pasadas que el modelo tomará como referencia para realizar predicciones. En segundo lugar, se definió un conjunto de validación, reservando el 20 % final de la serie temporal como conjunto de test, de manera que los modelos pudieran ser evaluados sobre datos no vistos durante el entrenamiento.

Introducción de lags: justificación y procedimiento

Los lags constituyen una herramienta fundamental en el modelado de series temporales, ya que permiten capturar dependencias históricas en los datos. En este caso, los lags se introdujeron como un vector que es interpretado automáticamente por las funciones de ajuste correspondientes a cada modelo de regresión. Dado que aún no se había definido el modelo óptimo, se optó por establecer un conjunto de lags básicos representativos de diferentes horizontes temporales: 1, 6, 12, 24 y 60 meses. Posteriormente, se contempla la posibilidad de optimizar estos valores para mejorar el rendimiento predictivo.


Una vez completado el proceso de entrenamiento, y teniendo en cuenta los lags definidos y el conjunto de test, se procedió a evaluar cada modelo. A continuación, se presentan los resultados obtenidos para cada uno de ellos bajo ambos enfoques de predicción.

Modelo	MAE Relativo (Recursive)	MAE Relativo (Direct)
Ridge	2.668.928	7.304.583
GradientBoosting	2.672.130	7.455.022
SVR	5.263.925	8.229.668
MLP	2.600.302	15.290.618

Tras evaluar el rendimiento de los distintos modelos, se ha decidido descartar el uso de Support Vector Regression (SVR), dado que presentó un error relativo significativamente mayor en comparación con el resto de modelos. Asimismo, se ha descartado el MLPRegressor, ya que, aunque su rendimiento en el método recursivo fue similar al de otros modelos en términos de error absoluto medio (MAE), su coste computacional es considerablemente más elevado, lo que lo hace menos eficiente para este tipo de tareas.

En consecuencia, se seleccionaron los modelos Ridge Regression y Gradient Boosting Regressor, dado que ambos ofrecieron los mejores resultados en términos de ajuste y eficiencia. A partir de esta selección, se procederá a experimentar con distintos valores de lags y ajustes de hiperparámetros, aplicando tanto el enfoque recursivo como el directo, con el fin de determinar cuál de las dos metodologías ofrece un desempeño más robusto y coherente con la naturaleza de los datos.

Como paso complementario, se llevará a cabo un análisis de tendencia, estacionalidad y componente residual para ambos modelos seleccionados, utilizando la función `seasonal_decompose` de la librería `statsmodels`. Este análisis se aplicará a las



predicciones obtenidas bajo ambos enfoques (directo y recursivo), con el objetivo de interpretar la estructura interna de las series pronosticadas y evaluar hasta qué punto los modelos son capaces de capturar adecuadamente la dinámica temporal de la variable objetivo.


En una primera comparación, el método recursivo parece captar de forma más efectiva las tendencias generales de la serie temporal. Sin embargo, en lo que respecta a la estacionalidad y a los componentes residuales, ambos enfoques —recursivo y directo— presentan resultados similares, sin diferencias sustanciales en la calidad de la descomposición.

Para la optimización de los lags, se ha recurrido nuevamente a la librería `statsmodels`, específicamente a las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF). Estas herramientas permiten analizar la dependencia temporal de la serie y evaluar la relevancia de los diferentes lags. En particular, las funciones ACF y PACF proporcionan información clave sobre:

La significancia individual de cada lag, es decir, si determinados retrasos (por ejemplo, de 1, 6 o 12 meses) aportan valor predictivo.

La interacción entre lags, permitiendo determinar si la inclusión de múltiples lags es redundante o si añaden información complementaria.

Esta información resulta fundamental para refinar la estructura del modelo y mejorar la capacidad predictiva del ajuste. A continuación, se presenta la visualización de las funciones ACF y PACF, que servirán como guía para la selección óptima de rezagos en los modelos Ridge y Gradient Boosting.




En la gráfica de autocorrelación, las barras verticales representan la intensidad de la relación entre los valores actuales de la serie y sus valores en periodos anteriores (rezagos). Cuando una barra sobresale del área sombreada en azul —que representa el intervalo de confianza del 95 %—, se considera que el rezago correspondiente tiene una correlación estadísticamente significativa con la serie. En cambio, las barras que permanecen dentro de esa zona pueden interpretarse como fluctuaciones aleatorias sin relevancia predictiva.

El análisis visual de esta gráfica revela que los primeros lags presentan una correlación notablemente alta, lo cual indica una dependencia temporal fuerte en los periodos más recientes. A partir de los rezagos cercanos al mes 40, la mayoría de las correlaciones dejan de ser significativas, lo que sugiere una pérdida progresiva de capacidad explicativa a medida que aumenta la distancia temporal.

Con base en este análisis, se procedió a probar distintos vectores de lags para optimizar el rendimiento de los modelos. Los resultados indican que el mejor desempeño —en términos de métricas como el error relativo— se obtiene utilizando un vector de lags continuo desde 1 hasta 35 meses. Esta elección concuerda con lo

observado en las gráficas de autocorrelación y autocorrelación parcial. Si bien es cierto que este ajuste no mejora de forma drástica respecto a una selección más simple (por ejemplo, lags de 1, 6, 12 y 24 meses), el aumento en el coste computacional es marginal, dado el tamaño moderado del conjunto de datos. Por tanto, se opta por mantener este conjunto ampliado de lags con el objetivo de aprovechar al máximo la información temporal contenida en la serie.

Para comparar el rendimiento de los modelos seleccionados, se graficaron sus predicciones bajo los enfoques recursivo y directo. Las figuras muestran las estimaciones de Net Generation generadas por los modelos Ridge y Gradient Boosting, junto con la serie real del conjunto de test. Esta visualización permite evaluar de forma clara la calidad del ajuste, la estabilidad temporal y la capacidad de los modelos para capturar tendencias y estacionalidad:



El análisis de las predicciones muestra que el método recursivo tiende a generar resultados más estables, particularmente en cuanto a la continuidad de las tendencias. No obstante, al observar que el error relativo del método directo se mantiene dentro de márgenes aceptables tanto en los modelos de Ridge como de Gradient Boosting, se ha optado por continuar con el método directo. Esta elección se justifica por su mayor realismo en la representación de la evolución futura, ya que permite capturar mejor la posible variabilidad interanual. Es razonable suponer que, aunque la tendencia a largo plazo sea positiva, el crecimiento no será completamente lineal, debido a factores como actualizaciones tecnológicas, mantenimiento programado o imprevistos de carácter climático o político, que pueden afectar negativamente la producción en años específicos.

Entre los dos modelos considerados en esta fase final, ambos presentan un error relativo aceptable y una capacidad adecuada para capturar la estacionalidad y la dinámica realista de la variable Net Generation. Sin embargo, el modelo Gradient

Boosting, aunque ligeramente más preciso en algunos casos, supone un mayor coste computacional. Si bien este aspecto no representa un problema crítico dado el volumen actual de datos, la diferencia marginal en rendimiento no justifica la penalización en eficiencia. Por tanto, se selecciona el modelo Ridge, configurado con lags comprendidos entre el mes 1 y el mes 35, utilizando el método directo de predicción.

Respecto a las variables exógenas (Net Summer Capacity y Capacity Factor (%)), se ha optado por modelarlas mediante una regresión SARIMAX. Esta decisión se basa en la estabilidad observada en ambas series, especialmente en los años más recientes, que son los de mayor relevancia para las predicciones. En ambas variables, tanto el primer percentil como la mediana se encuentran cercanos a sus valores máximos históricos, lo que indica una tendencia consolidada. Dado este comportamiento, un modelo estadístico como SARIMAX, que es eficiente computacional y suficientemente robusto para este tipo de series, resulta apropiado para estimar su evolución futura.


Resultados:

A pesar de la incertidumbre inherente a la predicción de variables futuras, se ha logrado un ajuste satisfactorio respecto a los datos históricos, y en particular, una representación de Net Generation que podría considerarse realista dentro del contexto energético actual. En la discusión final se analizará cómo estas proyecciones podrían influir en el mercado energético y en el desarrollo futuro de la energía nuclear.

Las predicciones obtenidas mediante el modelo Ridge para Net Generation y el modelo SARIMAX para las variables exógenas Net Summer Capacity y Capacity Factor (%) se han integrado en un gráfico interactivo disponible en la plataforma Streamlit: [Proyecto Energía Nuclear Streamlit](#)

Desde esta interfaz también es posible descargar los valores predichos para su análisis detallado.

A continuación, se presentan las gráficas generadas con los modelos seleccionados:



Conclusiones

Uno de los principales factores que motiva el interés por la construcción de nuevas centrales nucleares es su elevada capacidad de generación energética combinada con bajas emisiones de gases de efecto invernadero. Aunque el coste inicial de estas infraestructuras es considerablemente alto, se trata de una inversión que resulta rentable en el largo plazo. El coste de construcción de una central nuclear varía según la región y el diseño del reactor, pero se estima generalmente entre los 6.000 y los 9.000 millones de dólares por unidad. En términos de capacidad, esto equivale a aproximadamente 5.500 USD por kilovatio instalado. Estos costes elevados se deben, entre otros factores, a los estrictos requisitos regulatorios, las sofisticadas medidas de seguridad, la complejidad tecnológica y la duración del proceso de construcción, que puede extenderse entre cinco y diez años (World Nuclear Association, 2022).

No obstante, los costes de operación y mantenimiento de las plantas nucleares son relativamente bajos en comparación con otras fuentes de generación. A pesar de requerir personal técnico altamente especializado y sistemas de seguridad robustos, la elevada eficiencia de estas instalaciones y su prolongada vida útil —de entre 40 y 60 años, con posibilidades de extensión hasta los 80 años— permiten una amortización progresiva de la inversión. En condiciones óptimas, el plazo estimado de recuperación de la inversión oscila entre los 20 y los 30 años, tras lo cual la planta puede seguir operando con márgenes de beneficio positivos.

Desde una perspectiva comparativa, el coste nivelado de generación eléctrica (LCOE, por sus siglas en inglés) de la energía nuclear es competitivo respecto a otras fuentes tradicionales, como el gas natural o el carbón. Además, cuando se consideran los costes ambientales asociados a las emisiones, la energía nuclear se presenta como una alternativa aún más ventajosa. Si bien fuentes renovables como la solar y la eólica presentan menores costes de instalación, su naturaleza intermitente requiere sistemas de almacenamiento o respaldo que encarecen el sistema eléctrico en su conjunto.

En lo que respecta al combustible, la energía nuclear también muestra una clara ventaja económica. El uranio representa solo entre el 5 % y el 10 % del coste total de generación eléctrica, mientras que en plantas de carbón o gas este porcentaje puede superar el 60 % del coste total. Además, la densidad energética del uranio y su relativa estabilidad de precios en el mercado internacional contribuyen a reducir la volatilidad del coste energético a largo plazo (World Nuclear Association, 2022).

Si bien las cifras actuales ya posicionan a la energía nuclear como una de las fuentes más eficientes y fiables del panorama energético, las proyecciones a futuro sugieren una mejora continua en sus indicadores operativos. En particular, se espera que tanto la eficiencia energética como el factor de capacidad —es decir, el porcentaje del tiempo en que la planta opera a máxima potencia— continúen incrementándose gracias a los avances tecnológicos, la automatización de procesos y la optimización de los protocolos de mantenimiento. Aunque estas estimaciones están sujetas a cierta incertidumbre, la tendencia observada en las últimas décadas respalda la viabilidad de estos escenarios. En consecuencia, la inversión en energía nuclear no solo resulta

justificable en el presente, sino que podría adquirir aún mayor valor estratégico en el contexto energético de las próximas décadas.

Consideraciones:

A parte de la evolución de la producción de la energía nuclear, hay un par de puntos clave, que no se han estudiado en este proceso, pero que son claves también en cuanto al futuro de las plantas nucleares.

A pesar de la percepción social de que la energía nuclear implica elevados riesgos para la seguridad, los datos empíricos desmienten esta idea. De hecho, cuando se analiza el número de muertes por teravatio-hora (TWh) generado, la energía nuclear se sitúa como una de las fuentes más seguras de electricidad. Según Ritchie y Roser (2020), la nuclear produce apenas 0.03 muertes por TWh, una cifra comparable a la de la energía solar y eólica, y muy inferior a la del carbón (24.6) o el petróleo (18.4). Incluso considerando accidentes históricos como Chernóbil o Fukushima, el impacto total en términos de vidas humanas es notablemente bajo en relación con la cantidad de energía producida.

En paralelo, el desarrollo de la energía de fusión —aún en fase experimental— representa una prometedora evolución de la tecnología nuclear. La fusión, que imita el proceso energético del Sol, tiene el potencial de producir grandes cantidades de energía sin generar residuos de larga duración ni riesgo de accidentes catastróficos. Iniciativas internacionales como el reactor ITER en Francia, así como proyectos privados como SPARC (en colaboración con el MIT), sugieren que en las próximas dos décadas podrían alcanzarse avances significativos hacia la viabilidad comercial de esta fuente de energía (U.S. Department of Energy, 2023).

Además de la construcción de nuevas centrales, la modernización de plantas nucleares existentes representa una vía eficiente para ampliar la capacidad instalada. Esta estrategia incluye mejoras tecnológicas, extensiones de vida útil y actualizaciones en los sistemas de seguridad. En países como Estados Unidos, diversas instalaciones han recibido autorizaciones para operar durante hasta 80 años gracias a estos procesos de renovación (NRC, 2023). Asimismo, la introducción de reactores modulares pequeños (SMR) podría facilitar la expansión de la energía nuclear a regiones menos industrializadas o con menores recursos.

En lo relativo a la gestión de residuos, otro de los puntos críticos habitualmente señalados, cabe destacar que existen soluciones técnicamente sólidas y altamente controladas. El volumen de residuos nucleares es relativamente reducido en comparación con los generados por otras fuentes de energía, y pueden almacenarse de forma segura durante décadas. Países como Finlandia están desarrollando soluciones de almacenamiento geológico profundo, mientras que la investigación en reprocesamiento y reciclaje de combustible sigue avanzando. Según la World Nuclear Association (2023), el manejo de residuos de alta actividad está regulado con estándares de seguridad muy estrictos, lo cual garantiza una gestión eficaz y con riesgo mínimo para la población y el medio ambiente.

Referencias:

<https://world-nuclear.org/information-library/economic-aspects/economics-of-nuclear-power>

<https://www.eia.gov/nuclear/data.php#nuclear>

<https://www.kaggle.com/datasets/alistairking/nuclear-energy-datasets>

<https://ourworldindata.org/safest-sources-of-energy>

<https://www.energy.gov/ne/articles/5-fast-facts-about-nuclear-energy>

<https://www.nrc.gov/reactors/operating/licensing/renewal.html>

<https://world-nuclear.org/information-library/nuclear-fuel-cycle/nuclear-wastes/radioactive-waste-management.aspx>

<https://www.energy.gov/ne/articles/nuclear-waste-101>